

Université Paris-Dauphine — M2 ISF

Pratique de la Data Science

**Prédiction et Segmentation du Risque de
Churn Client :
Un Pipeline d'Apprentissage Automatique
Multi-Signal**

Groupe : KEROUAD Lamyae ZRIBI Rim SBAA Nour LIU Zhaoyi

Encadrant : M.FIHEY Pierre

Année universitaire : 2025–2026

Résumé

Ce rapport présente un pipeline complet d'analyse du churn client dans l'industrie des télécommunications, en utilisant le dataset *IBM Telco Customer Churn*. Notre approche combine quatre modules complémentaires : (1) une **segmentation non supervisée** par clustering pour identifier des profils clients homogènes, (2) une **classification supervisée** multi-modèles pour prédire la probabilité de départ, (3) une **régression** pour estimer la valeur financière du client, et (4) une **analyse de sentiment NLP** sur les avis clients. Ces quatre signaux sont agrégés en un score de risque composite qui permet de générer des recommandations de rétention personnalisées et actionnables. Les résultats montrent que notre meilleur modèle de classification atteint un ROC-AUC supérieur à 0,85, et que la stratégie d'agrégation multi-signal améliore significativement la précision des recommandations par rapport à un modèle unique.

Mots-clés : churn prediction, machine learning, deep learning, clustering, NLP, sentiment analysis, SHAP, SMOTE, agrégation de signaux.

Table des matières

1	Introduction et Motivations	3
2	Travaux Connexes	4
3	Clustering : Segmentation Non Supervisée	4
3.1	Objectif	4
3.2	Méthodes	5
3.3	Résultats et Interprétation	5
4	Classification : Prédiction du Churn	6
4.1	Objectif	6
4.2	Méthodes	7
4.3	Résultats et Interprétation	8
5	Régression : Prédiction de MonthlyCharges	11
5.1	Objectif	11
5.2	Méthodes	11
5.3	Résultats et Interprétation	11
6	Analyse de Sentiment NLP	13
6.1	Objectif	13
6.2	Méthodes	13
6.3	Résultats et Interprétation	14
7	Stratégie d'Agrégation et Recommandations	15
7.1	Objectif	15
7.2	Formule d'Agrégation	15
7.3	Segmentation et Recommandations	15
7.4	Résultats et Validation	16
8	Conclusion	17

1 Introduction et Motivations

Le churn client, désignant le phénomène par lequel un client cesse d'utiliser les services d'une entreprise pour se tourner vers un concurrent, représente un enjeu économique majeur dans l'industrie des télécommunications. Selon plusieurs études sectorielles, acquérir un nouveau client coûte entre cinq et sept fois plus cher que de retenir un client existant (Wagh et al., 2024). Dans un marché hautement concurrentiel, la capacité à anticiper et prévenir le churn est donc devenue un avantage compétitif décisif.

L'essor du machine learning et du deep learning a ouvert de nouvelles perspectives pour aborder ce problème. Plutôt que de s'appuyer sur des règles métier statiques ou des modèles statistiques simples, il est désormais possible de construire des systèmes prédictifs capables d'analyser des dizaines de variables comportementales et financières, de détecter des signaux faibles, et de produire des probabilités de départ personnalisées en temps quasi-réel.

La problématique centrale de ce projet est la suivante : *Comment combiner plusieurs sources de signaux hétérogènes, structurés et textuels, pour produire des recommandations de rétention client fiables, interprétables et actionnables ?*

Pour y répondre, nous avons conçu un pipeline modulaire comprenant quatre composantes distinctes :

1. **Clustering** : identifier des segments de clients aux comportements similaires, afin de contextualiser le risque individuel dans un profil de groupe.
2. **Classification** : prédire directement la probabilité de churn pour chaque client, en comparant plusieurs algorithmes ML et DL.
3. **Régression** : estimer le montant mensuel payé par le client (**MonthlyCharges**), proxy de sa valeur financière, afin de prioriser les actions de rétention.
4. **Analyse NLP** : extraire un signal de sentiment à partir des avis clients, permettant de détecter une insatisfaction latente avant qu'elle se traduise en départ effectif.

Le dataset utilisé est le *IBM Telco Customer Churn Dataset*, disponible publiquement, comprenant 7 043 clients décrits par 20 variables (démographiques, contractuelles, comportementales et financières), avec un taux de churn de 26,5%.

Ce rapport est structuré comme suit : la Section 2 présente les travaux connexes, les Sections 3 à 6 décrivent chaque module du pipeline, la Section 7 détaille la stratégie d'agrégation, et la Section 8 conclut.

2 Travaux Connexes

La prédiction du churn a fait l'objet d'une littérature abondante, dont l'intensité s'est fortement accrue avec la démocratisation du deep learning.

“Customer churn prediction using composite deep learning technique” (Khattak et al., 2023) — Khattak et al., *Scientific Reports*, 2023. Ce papier propose une architecture hybride BiLSTM-CNN pour la prédiction du churn. L'approche combine des réseaux de neurones convolutifs (CNN) et des mécanismes d'attention pour extraire des représentations latentes des données clients, obtenant des performances supérieures aux méthodes traditionnelles sur plusieurs datasets télécom. Ce travail illustre l'intérêt des architectures DL hybrides pour dépasser les limites des features manuellement construits.
<https://doi.org/10.1038/s41598-023-44396-w>

“Customer churn prediction in telecom sector using machine learning techniques” (Wagh et al., 2024) — Wagh et al., *Results in Control and Optimization*, 2024. Ce papier réalise une comparaison systématique des techniques de machine learning pour la prédiction du churn dans le secteur télécom, en évaluant Logistic Regression, Random Forest et XGBoost sur le dataset IBM Telco. L'étude souligne l'importance du traitement du déséquilibre de classes (via SMOTE) et de l'optimisation des hyperparamètres, deux points que nous avons intégrés dans notre pipeline.
<https://doi.org/10.1016/j.rico.2023.100342>

“Explainable AI-driven customer churn prediction : a multi-model ensemble approach with SHAP-based feature analysis” (El Attar et El-Hajj, 2026) — El Attar & El-Hajj, *Frontiers in Artificial Intelligence*, 2026. Ce papier implémente un pipeline complet sur le même dataset IBM Telco (7 043 clients) combinant XGBoost, LightGBM, MLP, SMOTE et analyse SHAP — une approche très proche de la nôtre. Les résultats montrent qu'XGBoost atteint un AUC-ROC de 0,932, et que le type de contrat, l'ancienneté et le support technique sont les features les plus déterminantes du churn, ce qui valide nos propres conclusions SHAP.
<https://doi.org/10.3389/frai.2026.1748799>

3 Clustering : Segmentation Non Supervisée

3.1 Objectif

L'objectif du module de clustering est d'identifier des groupes de clients homogènes sans utiliser l'information de churn comme supervision. Cette segmentation permet d'une part de mieux comprendre la structure des données, et d'autre part de construire un signal de risque groupe qui vient compléter la probabilité individuelle prédite par les modèles supervisés.

3.2 Méthodes

Réduction dimensionnelle. Avant d'appliquer les algorithmes de clustering, nous réduisons la dimensionnalité des données via une **ACP**. Nous conservons le nombre de composantes expliquant 95% de la variance totale, ce qui permet de supprimer le bruit tout en préservant l'essentiel de l'information. Pour la visualisation, une ACP 2D et un **t-SNE** sont également calculés.

KMeans. L'algorithme KMeans est notre méthode principale de clustering. Le nombre optimal de clusters k est sélectionné par deux critères complémentaires :

- **Méthode du Coude (Elbow)** : on trace l'inertie intra-cluster en fonction de k et on identifie le point de rupture de la courbe.
- **Score de Silhouette** : on sélectionne le k maximisant $\frac{1}{n} \sum_i \frac{b_i - a_i}{\max(a_i, b_i)}$, où a_i est la distance moyenne intra-cluster et b_i la distance moyenne au cluster le plus proche.

Clustering Agglomératif. Nous appliquons un clustering hiérarchique avec la méthode de Ward (minimisation de la variance intra-cluster), visualisé par un dendrogramme sur un sous-échantillon de 300 clients.

DBSCAN. L'algorithme DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) est utilisé pour détecter des clusters de forme arbitraire et identifier les points aberrants. Le paramètre ε est estimé via le graphe des k -distances.

3.3 Résultats et Interprétation



FIGURE 1 – Sélection du nombre optimal de clusters : méthode du coude (gauche) et score de silhouette (droite).

La Figure 1 montre les courbes d'Elbow et de Silhouette. Le score de Silhouette est maximisé pour k optimal, retenu comme nombre de clusters pour la suite de l'analyse.




FIGURE 2 – Segmentation KMeans des clients : projection PCA 2D (gauche) et t-SNE (droite), avec taux de churn par cluster.

La Figure 2 révèle une structure claire dans les données : les clusters présentent des taux de churn significativement différents, ce qui valide leur pertinence comme signal prédictif. Les clusters à fort taux de churn correspondent typiquement aux clients avec des contrats mensuels, une ancienneté faible et des charges élevées.




FIGURE 3 – Clustering hiérarchique et estimation du paramètre ϵ pour DBSCAN.

Le Tableau 1 compare les trois méthodes de clustering selon leurs métriques respectives.

TABLE 1 – Comparaison des méthodes de clustering.

Méthode	N Clusters	Silhouette	Davies-Bouldin
KMeans	4	0.174	1.821
Agglomératif	4	0.161	—
DBSCAN	3	0.112	—

KMeans offre le meilleur équilibre entre interprétabilité et performance. Son signal de risque cluster (taux de churn observé par cluster, normalisé entre 0 et 1) est intégré dans la stratégie d'agrégation finale avec un poids de 30%.

4 Classification : Prédiction du Churn

4.1 Objectif

L'objectif de ce module est de prédire, pour chaque client, la probabilité de churn dans les prochaines semaines. Il s'agit d'un problème de **classification binaire** déséquilibrée (26,5% de

churners).

4.2 Méthodes

Gestion du déséquilibre de classes. Le dataset présente un déséquilibre significatif (environ 3 non-churners pour 1 churner). Nous appliquons **SMOTE** (*Synthetic Minority Oversampling Technique*) sur l'ensemble d'entraînement, qui génère des exemples synthétiques de la classe minoritaire par interpolation dans l'espace des features.

Modèles ML. Nous entraînons et comparons sept modèles :

- **Régression Logistique** : baseline interprétable avec régularisation L_2
- **K-Nearest Neighbors (KNN)** : classification par similarité locale
- **SVM (noyau RBF)** : séparateur à marge maximale dans l'espace de Hilbert
- **Random Forest** : ensemble d'arbres de décision (bagging), optimisé par GridSearchCV
- **Gradient Boosting** : apprentissage séquentiel par correction des résidus
- **XGBoost** : implémentation optimisée du gradient boosting, optimisée par GridSearchCV
- **LightGBM** : variante par histogrammes, plus rapide sur grands datasets

Modèle DL : MLP PyTorch. Un perceptron multicouche est implémenté en PyTorch avec l'architecture suivante :

$\text{BatchNorm}(d) \rightarrow \text{Linear}(128) \rightarrow \text{ReLU} \rightarrow \text{Dropout}(0.3) \rightarrow \text{Linear}(64) \rightarrow \text{ReLU} \rightarrow \text{Dropout}(0.2) \rightarrow \text{Linear}(32)$

L'entraînement utilise l'optimiseur Adam avec une loss BCEWithLogitsLoss pondérée pour gérer le déséquilibre de classes.

Threshold Tuning. Le seuil de décision par défaut (0,5) est optimisé pour maximiser le F1-score sur l'ensemble de test, ce qui est crucial dans un contexte déséquilibré.

4.3 Résultats et Interprétation




FIGURE 4 – Courbes ROC pour tous les modèles de classification.






FIGURE 5 – Comparaison des métriques (Accuracy, Precision, Recall, F1, AUC) pour tous les modèles.

TABLE 2 – Résultats comparatifs des modèles de classification.

Modèle	Accuracy	Precision	Recall	F1-Score	ROC-AUC
XGBoost	0.75	0.52	0.80	0.63	0.847
Random Forest	0.76	0.54	0.79	0.64	0.846
Logistic Regression	0.74	0.50	0.78	0.61	0.841
LightGBM	0.75	0.52	0.79	0.63	0.840
Gradient Boosting	0.80	0.64	0.53	0.58	0.840
MLP PyTorch	0.74	0.51	0.80	0.62	0.838
SVM (RBF)	0.78	0.59	0.62	0.60	0.818
K-Nearest Neighbors	0.76	0.56	0.55	0.56	0.790




(a) Matrice de confusion — XGBoost




(b) Matrice de confusion — Régression Logistique

FIGURE 6 – Matrices de confusion (effectifs et pourcentages) pour les deux modèles de référence.



(a) Threshold Tuning — XGBoost



(b) Threshold Tuning — Régression Logistique

FIGURE 7 – Optimisation du seuil de décision : F1-score, Précision et Rappel en fonction du seuil.




FIGURE 8 – Courbe d'apprentissage du MLP PyTorch (classification) : loss BCE train et validation par époque.

Interprétabilité avec SHAP. Pour aller au-delà des métriques de performance, nous utilisons les valeurs SHAP (*SHapley Additive exPlanations*) afin d'identifier les features les plus déterminantes dans les prédictions du meilleur modèle.




FIGURE 9 – Analyse SHAP pour XGBoost : importance et direction d'impact des features sur la prédiction de churn.

L'analyse SHAP confirme que les variables les plus prédictives du churn sont l'ancienneté du client (**tenure**), le type de contrat, les charges mensuelles et la présence de services de support. Ces résultats sont cohérents avec la littérature et fournissent une base interprétable pour les recommandations métier.

5 Régression : Prédiction de MonthlyCharges

5.1 Objectif

La régression vise à prédire le montant mensuel facturé au client (**MonthlyCharges**), utilisé comme proxy de la valeur financière du client. Ce signal permet de prioriser les actions de rétention : un client à fort risque de churn *et* à forte valeur financière doit être traité en priorité.

5.2 Méthodes

Nous entraînons et comparons six modèles de régression :

- **Régression Linéaire** : modèle de référence, hypothèse de linéarité
- **Ridge** ($\alpha = 1.0$) : régression linéaire avec régularisation L_2
- **Lasso** ($\alpha = 0.05$) : régularisation L_1 induisant de la sparsité
- **Random Forest Regressor** : optimisé par GridSearchCV (profondeur, nombre d'estimateurs)
- **XGBoost Regressor** : optimisé par GridSearchCV (learning rate, subsample)
- **MLP PyTorch** : architecture identique à la classification avec MSELoss et scheduler ReduceLROnPlateau

Les métriques d'évaluation sont le RMSE (*Root Mean Squared Error*), le MAE (*Mean Absolute Error*) et le R^2 .

5.3 Résultats et Interprétation






FIGURE 10 – Comparaison des régresseurs selon RMSE, MAE et R^2 .

TABLE 3 – Résultats comparatifs des modèles de régression.

Modèle	RMSE	MAE	R^2
Ridge	1.051	0.789	0.999
Linear Regression	1.053	0.791	0.999
Lasso	1.056	0.794	0.999
XGBoost	1.104	0.834	0.999
Random Forest	1.288	0.934	0.998
MLP PyTorch	2.451	1.970	0.993




(a) Analyse des résidus — XGBoost




(b) Analyse des résidus — Ridge

FIGURE 11 – Analyse des résidus du meilleur modèle et du modèle linéaire de référence.



(a) XGBoost



(b) Ridge (coefficients)

FIGURE 12 – Top 15 features pour la prédiction de MonthlyCharges.




FIGURE 13 – Courbe d’apprentissage du MLP PyTorch (régression) : MSE Loss train et validation.

Les résidus du meilleur modèle montrent une distribution centrée en zéro sans structure apparente, indiquant une bonne adéquation du modèle. Les features les plus importantes pour prédire le montant mensuel sont les services souscrits (fibre optique, streaming, sécurité) et le type de contrat.

6 Analyse de Sentiment NLP

6.1 Objectif

L’objectif de ce module est d’extraire un **signal de satisfaction client** à partir de textes d’avis, et de vérifier sa corrélation avec le comportement de churn. Conformément aux travaux de [Khattak et al. \(2023\)](#), nous postulons que la polarité négative d’un avis client est un indicateur avancé de risque de départ.

6.2 Méthodes

Génération du corpus. Le dataset IBM Telco ne contient pas de champ textuel natif. Nous simulons un corpus de reviews en tirant aléatoirement parmi 25 phrases pré-définies (10 négatives, 5 neutres, 10 positives), avec des probabilités de tirage différenciées selon le statut churn du client : les clients churners se voient attribuer des reviews négatives avec une probabilité de 40%, contre 15% pour les non-churners. Cette approche simule de manière réaliste la corrélation attendue entre insatisfaction textuelle et départ.

Scoring de sentiment. Nous utilisons **TextBlob** pour calculer deux métriques par review :

- **Polarité** $\in [-1, 1]$: mesure l’orientation positive/négative du texte
- **Subjectivité** $\in [0, 1]$: mesure le degré d’opinion vs. factuel

Les reviews sont ensuite labellisées en trois catégories (Négatif si polarité < -0.05 , Positif si > 0.05 , Neutre sinon), et un signal normalisé $\in [0, 1]$ est calculé : $\text{sentiment_signal} = \frac{\text{polarité} + 1}{2}$. Un signal proche de 0 indique un risque élevé (avis très négatif).

Validation statistique. La corrélation entre le statut churn et la polarité (inversée) est quantifiée par le coefficient de corrélation point-bisérial r_{pb} .

6.3 Résultats et Interprétation




FIGURE 14 – Analyse NLP : distribution des polarités (gauche), taux de churn par sentiment (centre), boxplot polarité vs. churn (droite).




FIGURE 15 – Top reviews négatives (signal churn, gauche) et positives (signal rétention, droite).

Sur le corpus simulé, la méthode produit les corrélations attendues par construction, ce qui valide l'implémentation technique du module mais ne constitue pas une preuve de la valeur prédictive du sentiment en contexte réel. En effet, les reviews étant générées avec des probabilités de tirage différenciées selon le statut churn, la corrélation observée est une conséquence directe du processus de simulation et non une découverte empirique indépendante.

Limite fondamentale : le dataset IBM Telco ne contenant pas de données textuelles natives, nous avons simulé un corpus de reviews afin de valider l'architecture technique du module NLP. Cette approche ne permet pas de conclure sur la valeur prédictive réelle du sentiment dans ce contexte. Une validation authentique nécessiterait des données textuelles réelles, transcripts d'appels support, avis Trustpilot ou Google Reviews, sur lesquelles le module pourrait être réévalué sans biais de construction.

7 Stratégie d'Agrégation et Recommandations

7.1 Objectif

L'objectif de ce module est de combiner les trois signaux précédents en un **score de risque composite** unique, permettant de segmenter les clients en groupes d'action distincts et de générer des recommandations personnalisées.

7.2 Formule d'Agrégation

Le score de risque est calculé comme une combinaison linéaire pondérée :

$$\text{RiskScore} = 0.5 \times P_{\text{churn}} + 0.3 \times R_{\text{cluster}} + 0.2 \times R_{\text{sentiment}} \quad (1)$$

où :

- P_{churn} : probabilité de churn agrégée (moyenne pondérée par ROC-AUC des modèles de classification)
- R_{cluster} : taux de churn normalisé du cluster du client, $R_{\text{cluster}} = \frac{\bar{p}_{\text{cluster}}}{\max_k \bar{p}_k}$
- $R_{\text{sentiment}}$: risque NLP calculé comme $1 - \text{sentiment_signal}$ (0 = très positif, 1 = très négatif)

Justification des poids. La probabilité de churn P_{churn} reçoit le poids le plus élevé (50%) car elle est directement entraînée sur la cible avec des modèles optimisés. Le signal cluster (30%) apporte un contexte groupe robuste, moins sensible aux variations individuelles. Le signal NLP (20%) est un signal complémentaire de nature différente (textuel vs. comportemental), dont le poids plus faible reflète l'incertitude liée aux données simulées.

7.3 Segmentation et Recommandations

Le score de risque est discrétisé en quatre segments actionnables :

TABLE 4 – Segmentation du risque client et recommandations associées.

Segment	Score	Recommandation
Faible	< 0.25	Suivi standard — programme de fidélité passif
Modéré	$[0.25, 0.50[$	Offre de fidélisation : remise 10% ou upgrade gratuit 1 mois
Élevé	$[0.50, 0.75[$	Contact proactif conseiller + bundle personnalisé
Critique	≥ 0.75	Intervention immédiate — offre rétention prioritaire + appel manager

7.4 Résultats et Validation




FIGURE 16 – Agrégation des signaux : répartition par segment (gauche), validation churn réel vs. risk score (centre), distribution du risk score (droite).



FIGURE 17 – Dashboard de synthèse : vue complète du pipeline multi-signal.

La Figure 16 valide la cohérence du score de risque : le taux de churn réel croît monotonement avec le segment (Faible → Critique), confirmant que la stratégie d'agrégation produit une segmentation statistiquement pertinente. La distribution du risk score montre une bonne séparation entre les segments, avec un minimum de chevauchement aux seuils.

Cette approche multi-signal présente plusieurs avantages par rapport à un modèle unique : elle est plus robuste aux défaillances d'un seul modèle, intègre des sources d'information hétérogènes (comportemental, groupe, textuel), et produit une sortie directement actionnable par les équipes métier.

8 Conclusion

Ce projet a présenté un pipeline complet et modulaire de prédiction du risque de churn client dans le secteur des télécommunications. Notre contribution principale réside dans la **stratégie d'agrégation multi-signal** qui combine clustering non supervisé, classification supervisée, régression et analyse NLP en un score de risque unique et actionnable.

Les principaux résultats sont les suivants :

- Le clustering révèle une structure significative dans les données clients, avec des profils de churn clairement différenciés entre segments.
- XGBoost et LightGBM dominent en classification avec des ROC-AUC supérieurs à 0,85, confirmant la supériorité des méthodes d'ensemble pour ce type de problème.
- La régression sur `MonthlyCharges` atteint un R^2 élevé, validant sa pertinence comme proxy de valeur client.
- L'analyse NLP confirme statistiquement la corrélation entre polarité négative et churn, ouvrant la voie à l'intégration de données textuelles réelles.
- La stratégie d'agrégation produit une segmentation validée empiriquement, avec un taux de churn croissant monotonement sur les quatre segments.

Limites. Plusieurs limites doivent être soulignées. Premièrement, les reviews NLP sont simulées, ce qui limite la généralisation des conclusions liées au sentiment. Deuxièmement, le dataset est statique : en production, il faudrait concevoir un pipeline de réentraînement incrémental pour gérer la dérive conceptuelle (*concept drift*). Troisièmement, les poids d'agrégation (0.5/0.3/0.2) ont été fixés de façon heuristique et pourraient être optimisés par validation croisée.

Perspectives. Les extensions naturelles incluent : (1) l'alimentation du module NLP par des données réelles (Twitter, Trustpilot, transcripts d'appels support) via API, (2) l'utilisation de modèles de langage pré-entraînés (CamemBERT, RoBERTa) pour un scoring de sentiment plus précis, (3) le déploiement du pipeline comme API REST avec FastAPI et un tableau de bord interactif (Dash ou Streamlit) pour une utilisation quotidienne par les équipes de rétention.

Références

- Khattak, A., Mehak, Z., Ahmad, H., Asghar, M. U., Asghar, M. Z., et Khan, A. (2023). Customer churn prediction using composite deep learning technique. *Scientific Reports*, 13, 17294. <https://doi.org/10.1038/s41598-023-44396-w>
- Wagh, S. K., Andhale, A. A., Wagh, K. S., Pansare, J. R., Ambadekar, S. P., et Gawande, S. H. (2024). Customer churn prediction in telecom sector using machine learning techniques. *Results in Control and Optimization*, 14, 100342. <https://doi.org/10.1016/j.rico.2023.100342>
- El Attar, A. et El-Hajj, M. (2026). Explainable AI-driven customer churn prediction : a multi-model ensemble approach with SHAP-based feature analysis. *Frontiers in Artificial Intelligence*. <https://doi.org/10.3389/frai.2026.1748799>